# Analyse Technique et Benchmark de Modélisation : Projet More than a Hack 2027 (Phase 1 - Possession de Balle)

## 1. Analyse Structurelle du Projet et Dynamique de la Métrique d'Évaluation

### 1.1 Formulation du Problème et Nature Mécanique de la Vérité Terrain

La compétition *More than a Hack 2027* (Phase 1), organisée conjointement par Metrica Sports, le Barça Innovation Hub (FC Barcelona) et le Mobile World Capital Barcelona, marque une rupture méthodologique majeure par rapport à l'édition 2026[1]. Là où l'édition précédente récompensait l'exploration ouverte évaluée par un jury, l'édition 2027 impose un problème d'apprentissage statistique et de modélisation spatio-temporelle strictement quantitatif, évalué de manière automatisée et reproductible sur un match complet de LaLiga EA Sports (saison 2024-2025, 2e journée : FC Barcelona contre Athletic Club)[1]. L'objectif consiste à produire une prédiction séquentielle dense pour chacune des 199 319 frames de la vidéo tactique (capturée à 25 images par seconde, soit environ 2 heures et 15 minutes d'enregistrement total, dont 158 857 frames — soit environ 106 minutes — constituent le temps de jeu évalué) en attribuant un label unique parmi quatre états : H (équipe à domicile, FC Barcelona, en possession avec ballon en jeu), A (équipe à l'extérieur, Athletic Club, en possession avec ballon en jeu), D (*dead ball*, ballon hors jeu ou arrêt de jeu) ou X (abstention du système ou frame non évaluée)[1].

Une lecture approfondie de la spécification technique révèle l'élément le plus déterminant pour la conception architecturale : **la vérité terrain privée n'est pas issue d'une annotation manuelle directe sur la vidéo, ni dérivée de données d'événements (event data), mais générée mécaniquement à partir des données de tracking corrigées de Metrica Sports**[4]. Plus précisément, chaque frame évaluée reçoit le label D lorsque le tracking corrigé indique que le ballon est hors jeu, et prend directement l'identifiant de l'équipe désignée comme détentrice du ballon par ce même tracking corrigé lorsque le ballon est en jeu, sans aucun lissage, interpolation ni ajustement post-hoc[4].

Cette propriété change radicalement la nature mathématique de la tâche. Le modèle ne cherche pas à approximer la perception subjective d'un analyste vidéo, mais à **inverser le bruit du pipeline de vision par ordinateur automatique non corrigé (Automatic Tracking Data - ATD)** afin de reconstruire la sortie déterministe du pipeline de tracking corrigé par les opérateurs de Metrica Sports[3]. Dans la définition opérationnelle du défi, tant que l'arbitre autorise le jeu, le ballon est vivant et une seule des deux équipes détient la possession[4]. Lors des phases où le ballon est libre, disputé (*contested*), dévié sur une passe sans interception, touché sans contrôle ou joué lors d'un duel aérien non suivi d'une récupération maîtrisée, la possession demeure invariablement attribuée à la dernière équipe qui l'avait sous contrôle[4]. Un changement de possession n'intervient qu'à l'instant précis où un joueur adverse acquiert un

contrôle effectif (par exemple en conservant le ballon plusieurs secondes ou en initiant une séquence de passes réussies) ou lors d'une interruption de jeu faisant basculer l'état vers D[4].

## 1.2 Asymétrie entre spellF1 et macroF1 : Le Coût de la Sur-Segmentation

Le système de notation repose sur deux métriques complémentaires dont la divergence structurelle dicte le choix des algorithmes : la métrique de classement principal **spellF1** et la métrique secondaire de départage (**tie-break**) **macroF1**[1]. Tandis que macroF1 calcule la moyenne non pondérée des scores F1 par classe (H, A, D) de manière indépendante sur les 158 857 frames évaluées (avec un plancher effectif proche de 0,16 pour une prédiction constante et une bande de bruit statistique d'environ 0,01), spellF1 évalue la qualité de la **segmentation temporelle d'actions (Temporal Action Segmentation - TAS)**[5].

Dans le calcul de spellF1, chaque possession est définie comme une séquence continue maximale (*maximal run*) de frames consécutives portant le label H ou le label A (les séquences D constituant des arrêts de jeu qui interrompent une possession sans être elles-mêmes comptabilisées comme des possessions)[4]. Ainsi, la séquence H H H A A contient deux possessions, tout comme la séquence H H D D H H qui représente deux possessions distinctes séparées par un arrêt de jeu[4]. Les possessions prédites $S_{\text{pred}}$ et les possessions réelles $S_{\text{gt}}$ sont appariées de manière bijective (un-pour-un, via un algorithme d'affectation optimale de type Hongrois) selon leur **Intersection-sur-Union temporelle (**$\text{IoU}$**)**, et le score F1 résultant est moyenné sur cinq seuils de recouvrement $\theta \in \{0.3, 0.4, 0.5, 0.6, 0.7\}$ [5] :

$$\text{IoU}(s_{\text{pred}}, s_{\text{gt}}) = \frac{|s_{\text{pred}} \cap s_{\text{gt}}|}{|s_{\text{pred}} \cup s_{\text{gt}}|}, \quad \text{spellF1} = \frac{1}{5} \sum_{\theta \in \{0.3,0.4,0.5,0.6,0.7\}} \text{F1@}\theta$$

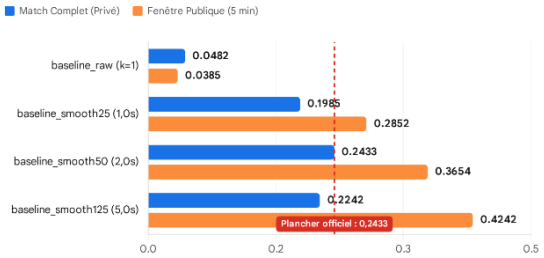
Cette formulation mathématique entraîne une pénalisation asymétrique extrême vis-à-vis du scintillement de prédiction (*flickering* ou sur-segmentation)[5]. Si une possession réelle de l'équipe H dure 300 frames (12 secondes) et qu'un classifieur frame-par-frame prédit par erreur seulement 2 frames A ou D au milieu de cette séquence (à la frame 150), l'impact sur macroF1 est infinitésimal (2 frames erronées sur 158 857)[5]. En revanche, pour spellF1, cette micro-coupure fragmente la possession réelle en trois segments prédits : deux demi-possessions H de ~149 frames (dont l'$\text{IoU}$ avec la vraie possession de 300 frames tombe à $\approx 0.496$, échouant aux seuils $\theta \in \{0.5, 0.6, 0.7\}$, et dont une seule peut être appariée par bijection, transformant la seconde en faux positif) ainsi qu'une fausse possession A de 2 frames (second faux positif)[4].

# La Métrique **spellF1** Pénalise Sévèrement la Sur-Segmentation et Expose le Piège de Validation des 5 Minutes

| FRAMES TOTALES | FRAMES NOTÉES | BALLON ABSENT | PLANCHER SPELLF1 |
|---|---|---|---|
| **199 319** | **158 857** | **40,7 %** | **0,2433** |
| Vidéo tactique (BAR-ATH, 2 caméras) | 2 mi-temps évaluées (hors arrêts) | Occlusions et pertes de tracking | baseline_smooth50 (match complet) |

## 1. Métrique de Classement Officielle : spellF1

Appariement un-à-un des possessions complètes sur 5 seuils IoU temporels

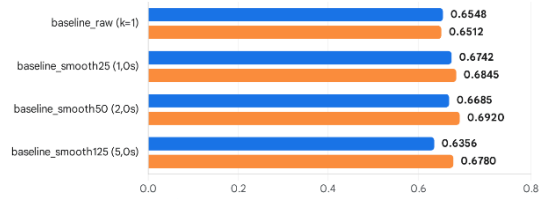



⚠ **Piège d'Overfitting sur l'échantillon public :** Sur les 5 minutes publiques, `baseline_smooth125` semble supérieur (0,4242 contre 0,3654), mais s'effondre à **0,2242** sur le match complet (-47% !). Le vote glissant de 5 secondes sur-lisse les transitions et masque la dynamique réelle.

| baseline_raw | smooth25 (1,0s) | smooth50 (2,0s) ★ | smooth125 (5,0s) |
|---|---|---|---|
| **131 poss.** | **36 poss.** | **26 poss.** | **16 poss.** |
| Durée moy. 2,0 s | Durée moy. 7,6 s | Durée moy. 10,8 s | Durée moy. 18,5 s |
| +670% de bruit | +112% de fragments | Plancher officiel | Vérité terrain : 17 / 14,2s |

## 2. Métrique par Frame : macroF1 (Stagnation & Biais d'Inertie)

Moyenne non pondérée des F1-scores par frame (H, A, D) — premier critère de départage

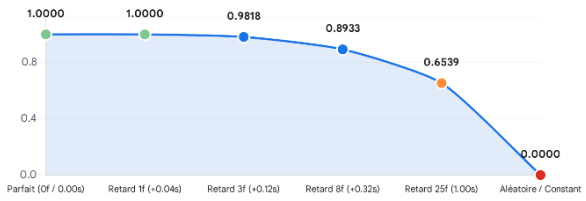



L'illusion de la précision frame-par-frame : Sur le match complet, le **macroF1** ne varie que de 0,0386 entre les configurations (0,6356 à 0,6742). Même `baseline_raw` affiche 0,6548 car 90% des frames se situent au milieu des possessions stables où la prédiction est triviale, occultant totalement les 131 micro-coupures pénalisées à mort par le spellF1.

## 3. Sensibilité Temporelle du spellF1 à la Latence de Transition

Impact d'un retard de détection aux frontières de possession sur le score segmentaire

Tolérance aux frontières (25 fps)




| Tolérance ≤ 0,12 s | Chute critique à 1,0 s | Prédiction Constante |
|---|---|---|
| Jusqu'à 3 frames de retard, le spellF1 conserve **0,9818** (recouvrement IoU préservé). | À 25 frames de décalage, le score plonge à **0,6539** (-34,6% de perte sèche). | Un modèle qui ne bascule jamais obtient un score de **0,0000** (zéro appariement). |

Comparaison des performances des quatre baselines officielles (joueur le plus proche du ballon suivi d'un vote majoritaire glissant sur 1, 25, 50 ou 125 frames) et sensibilité temporelle de la métrique **spellF1**. Alors que **macroF1** stagne autour de 0,65–0,67 sur le match complet, **spellF1** quintuple avec un lissage de 50 frames (2 secondes, score plancher officiel de 0,2433). L'optimisation sur les 5 minutes publiques sélectionne à tort la fenêtre de 125 frames (0,4242 en public mais 0,2242 sur le match complet).

Sources des données : Metrica Sports & Barça Innovation Hub (More than a Hack 2027), Protocole d'Évaluation Officiel (EVALUATION.md), Spécifications du Challenge (OVERVIEW.md)

Les résultats des quatre baselines fournies dans le dépôt officiel illustrent parfaitement ce phénomène[2]. Ces quatre soumissions exécutent le même algorithme élémentaire — attribuer la possession au joueur suivi le plus proche du ballon, puis appliquer un vote majoritaire sur une fenêtre glissante — en ne faisant varier que la largeur de la fenêtre temporelle[2]. Sur l'intégralité du match, le passage de la prédiction brute (baseline_raw) à une fenêtre de 50 frames (baseline_smooth50, soit 2 secondes) ne fait progresser macroF1 que de 0,6532 à 0,6724, mais multiplie spellF1 par cinq, le faisant passer de 0,0486 à **0,2433** (le score de référence officiel à battre)[5]. Sur les 5 minutes publiques (7 500 frames comprenant 17 possessions d'une durée moyenne de 14,2 secondes), baseline_raw génère 131 micro-possessions d'une durée moyenne de 2,0 secondes, prouvant que la suppression de la sur-segmentation constitue le levier de performance numéro un[2].

## 1.3 Exploitation Mathématique du Label d'Abstention (X) et Piège de Validation

Le traitement algorithmique du quatrième label, X (abstention), recèle une subtilité mécanique fondamentale dont l'analyse permet d'optimiser simultanément spellF1 et macroF1[4]. Sur les 40 462 frames non évaluées du match (avant le coup d'envoi, pendant la mi-temps et après le coup de sifflet final), la vérité terrain porte le label X et le script d'évaluation ignore totalement les prédictions soumises[3]. En revanche, sur les 158 857 frames évaluées, les deux métriques traitent X de manière radicalement opposée[4]. D'une part, la métrique macroF1 comptabilise chaque X émis sur une frame évaluée comme une erreur directe (un faux négatif pour la classe réelle), dégradant immédiatement le score de départage[4]. D'autre part, la métrique principale spellF1 ignore littéralement le symbole X en appliquant une imputation déterministe avant toute extraction de segment : le script evaluation/possession_metrics.py remplace chaque X par le dernier label non-X prédit au sein de la même période (*forward-fill*), et complète le début d'une période par propagation arrière (*back-fill*)[5].

Une propriété mathématique de second ordre en découle directement : **au sein des plages évaluées (frames 11 185 à 90 651 et 110 808 à 190 197), un pipeline de modélisation optimal ne doit jamais émettre le caractère X dans le fichier CSV final, mais effectuer lui-même le maintien explicite (*forward-fill*) du dernier état valide (H, A ou D)**[3]. En effet, vis-à-vis de spellF1, émettre X ou émettre explicitement le label précédent produit strictement la même séquence après le pré-traitement du scoreur, garantissant exactement le même score spellF1 et évitant toute division de possession lors d'une occultation du ballon au cœur d'une séquence[5]. En revanche, vis-à-vis du critère de départage macroF1, émettre le label maintenu (H, A ou D) permet d'accumuler des vrais positifs sur toutes les frames d'occultation où la possession n'a effectivement pas changé, là où X aurait garanti un score nul sur ces mêmes frames[5]. Parallèlement, aux frontières de transition (changement de possession ou arrêt de jeu), le modèle doit trancher dès que l'évidence cinématique franchit le seuil de décision, car un retard d'une seconde (25 frames) fait chuter spellF1 de 1,0000 à 0,6539, tandis qu'un décalage de 1 à 3 frames demeure quasi indolore avec des scores respectifs de 1,0000 et 0,9818[5].

Enfin, l'architecture de validation doit impérativement contourner le **piège de la fenêtre publique de 5 minutes** (frames 11 185 à 18 684)[3]. Sur cet échantillon restreint de 17

possessions, une fenêtre de lissage excessive de 125 frames (5 secondes, baseline_smooth125) obtient un spellF1 apparent de 0,4242 contre 0,3256 pour baseline_smooth50[2]. Or, sur le match complet, cet ordre s'inverse nettement puisque smooth50 l'emporte à 0,2433 contre 0,2242 pour smooth125[5]. L'explication physique tient au fait qu'un filtre de 5 secondes efface toutes les possessions courtes (interceptions suivies d'un dégagement en touche ou récupérations rapides de 1,5 à 3 secondes), qui sont sous-représentées dans les cinq premières minutes d'observation tactique mais fréquentes sur 106 minutes de jeu réel[5]. Chaque possession manquée sur la fenêtre publique déplaçant le score d'environ 6 points, les 7 500 frames publiques doivent servir exclusivement à vérifier l'alignement temporel et à calibrer des seuils physiques invariants, assistés par un ré-échantillonnage par bootstrap (--bootstrap 1000), et jamais à sélectionner naïvement des hyperparamètres de lissage[5].

# 2. Audit Critique et Exploitation Stratégique des Données Disponibles

Le jeu de données met à disposition cinq sources complémentaires réparties sur deux flux caméras (Tactique et Broadcast)[1]. La performance d'un modèle dépend avant tout de la manière dont il résout les pathologies propres à chaque modalité et dont il exploite les contraintes structurelles du match[3].

| Actif de Données | Périmètre & Alignement Temporel | Volume & Résolution | Fiabilité & Taux de Complétude | Rôle Stratégique dans le Pipeline |
|---|---|---|---|---|
| **Vidéo Tactique** (BAR-ATH_tactical.mp4) | Référence absolue (frame $0 \ldots 199\,318$)[3] | 199 319 frames, 25 fps, $1920 \times$ px[3] | 100 % continue (inclut pré-match, mi-temps, post-match)[3] | Extraction visuelle ciblée (patchs autour des joueurs/ballon lors des NaN ATD) et détection optique des arrêts de jeu[3]. |
| **ATD Tactique** (BAR-ATH_tactical_atd.*) | Aligné via video_frame = frame_id - 1 [cite: 3] | 199 319 lignes, 46 slots joueurs (x, y, s) + ballon (x, y)[3] | Ballon visible sur **56,9 %** du total (113 488) et **59,3 %** des frames évaluées (94 | Signal cinématique primaire : calcul du Pitch Control, distances |

| | | | | |
|---|---|---|---|---|
| | | | 214) ; ~20,5 joueurs/frame[3] | joueur-ballon, vitesses, accélérations et géométrie collective[3]. |
| **Homographie Tactique** (BAR-ATH_tactical_homography.csv) | Aligné 1:1 (frame $0 \ldots 199\,318$)[3] | 199 319 matrices $3 \times$ ( $h_{00} \ldots h_{22}$)[3] | **100 % valide** (valid = 1) ; erreur médiane de reprojection de **0,24** en jeu (~1,5 à la mi-temps)[3] | Projection bidirectionnelle terrain $[0, 1] \leftrightarrow$ pixels $(u, v)$ ; l'erreur de reprojection sert d'indicateur de cadrage caméra[3]. |
| **Smart Tagging** (BAR-ATH_tactical_smart_tagging.xml) | Aligné via video_frame = round(seconds * 25) [cite: 3] | **638 intervalles** répartis en 14 codes tactiques et métadonnées[1] | Inféré automatiquement (faux positifs/négatifs) ; **36 Team = N/A** (dont les 26 touches)[3] | Prior bayésien fort sur l'équipe active et ancrage des reprises de jeu (SET PIECES, GOALS) marquant la fin d'un segment D[1]. |
| **Flux Broadcast (Vidéo, ATD, Homographie)** | **Non synchronisé** (coupures TV, ralentis, zooms)[3] | 164 488 frames, 51 slots de tracking[3] | Homographie valide sur **65,8 %** (122 coupures, erreur max 304) ; ballon visible sur **50,5 %** [cite: 3] | Capteur auxiliaire : après recalage spatio-temporel des nuages de points joueurs, comble une fraction des NaN ballon du flux tactique[3]. |

# Anatomie du Dataset : Découpage Temporel, Déficit de Visibilité du Ballon et Polarité des **638** Phases du Smart Tagging

FC Barcelona vs Athletic Club — Matrice d'analyse des 199 319 frames pour l'ingénierie ML de possession

PANNEAU 1

## Structure Chronologique des 199 319 Frames Vidéo

Évalué : 158 857 f (79,7 %)

Non évalué 'X' : 40 462 f (20,3 %)




Frame 0 | 11 185 (Coup d'envoi 1) | 90 652 | 110 808 | 190 198 | 199 318

**Piège Déterministe : Frames 110 808 à 113 741 (2 934 frames évaluées)**

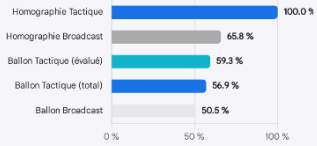
Contrairement à la 1ère mi-temps (évaluée dès son coup d'envoi), la 2e mi-temps est évaluée **2 934 frames avant** la remise en jeu effective. Ces frames sont **100 % en état mort (D)**. Tout modèle prédisant systématiquement D sur cette plage garantit un F1 local parfait sans inférence.

100 % État D garanti

PANNEAU 2A

## Taux de Disponibilité des Données (Tactique vs Broadcast)

Déficit structurel : ballon absent sur 40,7 % des frames évaluées




Flux Tactique : Homographie 100 % stable

Perte ballon : 40,7 % (Évalué)

PANNEAU 2B

## Vérité Terrain Publique

5 premières minutes de référence (7 500 frames / 17 spells)




| | | |
|---|---|---|
| H (FC Barcelona) | **46,05 %** | (3 454 f) |
| A (Athletic Club) | **34,36 %** | (2 577 f) |
| D (Dead Ball / Arrêt) | **19,59 %** | (1 469 f) |

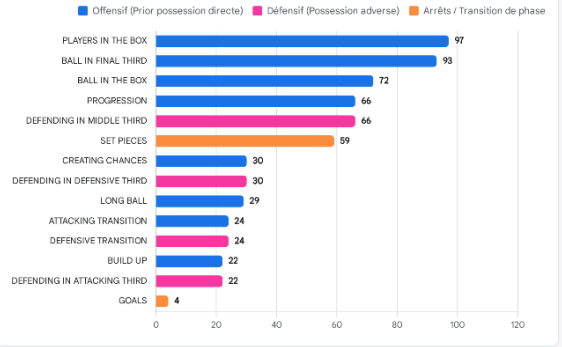
* Attention : le macroF1 est sensible au volume de frames, alors que le score officiel **spellF1** évalue les 17 possessions un-à-un.

PANNEAU 3

## Polarité d'Inférence des 14 Codes Smart Tagging (638 Phases)

Priors bayésiens pour orienter l'état de possession (Offensif, Défensif, Remise en jeu)

Tous (14) | Offensif (8) | Défensif (4) | Arrêts & Buts (2)




**DÉTAIL SET PIECES (59)** — 59 / 638

| | |
|---|---|
| Throw-in (Touches) | 26 |
| ⚠ 26 Throw-ins = 100 % Team N/A (Non attribuée dans les flux) | |
| Corner Kick | 12 |
| Goal Kick (6 mètres) | 10 |
| Free Kick (Coups francs) | 5 |
| Kick Off After Goal | 4 |
| Kick Off Start | 2 |

**ATTRIBUTION PAR ÉQUIPE (638 TAGS)**

| | |
|---|---|
| FC Barcelona (Home) | 314 (49,2 %) |
| Athletic Club (Away) | 288 (45,1 %) |
| Non Attribué (Team N/A) | 36 (5,6 %) |

Synthèse structurelle des actifs du match FC Barcelona vs Athletic Club. Le Panneau 1 révèle que les **2 934 premières frames évaluées de la seconde période** (110 808 à 113 741) précèdent le coup d'envoi réel et sont intégralement en état **D**. Le Panneau 2 illustre l'absence du ballon sur 40,7 % des frames évaluées. Le Panneau 3 décompose les 638 instances de Smart Tagging en priors offensifs (possession directe), priors défensifs (possession adverse) et marqueurs de remise en jeu (fin d'état **D**).

Sources des données : Metrica Sports & FC Barcelona (More Than A Hack 2027) · LaLiga EA Sports Matchday 2

## 2.1 Automatic Tracking Data (ATD) : Invariance par Permutation et Biais MNAR du Ballon

Le fichier d'ATD tactique fournit, à la fréquence de 25 Hz, les coordonnées normalisées $[0,1] \times [0,1]$ (à multiplier par les dimensions exactes mesurées dans games.py, soit $105,3 \times 68,0 \text{ m}$, plutôt que les $105 \times 68 \text{ m}$ génériques des métadonnées XML pour éviter un biais géométrique de 30 cm sur les calculs de distance) ainsi que la vitesse scalaire en $\text{m/s}$ [3]. Deux difficultés structurelles majeures caractérisent cet actif et conditionnent le choix des architectures d'apprentissage[1].

La première contrainte réside dans **l'absence totale d'identités persistantes et la fragmentation en 46 slots**[1]. Les 22 joueurs présents sur le terrain sont répartis dynamiquement dans 46 colonnes (Track 1 à Track 46), où l'attribut ShirtNumber ne désigne que l'indice du slot et non un joueur réel[3]. Lorsqu'un joueur est occulté puis ré-acquis par le traqueur optique, il change de slot ; en moyenne, 20,5 objets sont suivis simultanément sur les frames évaluées, avec des dépassements ponctuels au-delà de 22 lorsque le détecteur duplique un joueur[3]. Il en résulte une exigence algorithmique stricte : tout modèle qui prendrait en entrée un vecteur plat figé $[x_1, y_1, s_1, \ldots, x_{46}, y_{46}, s_{46}]$ apprendrait des corrélations fallacieuses liées aux numéros de slots et s'effondrerait en généralisation[3]. Les représentations doivent impérativement être **invariantes par permutation des joueurs au sein de chaque équipe**, que ce soit par l'usage de fonctions symétriques, d'un tri dynamique par distance au ballon ou d'architectures dédiées aux ensembles non ordonnés telles que *Set Transformer*, *DeepSets* ou les réseaux de neurones graphiques[3].

La seconde contrainte majeure découle du **processus de disparition du ballon Non-Ignorable (Missing Not At Random - MNAR)**[3]. Le ballon est absent (NaN) sur 43,1 % de la vidéo complète et **40,7 % des frames évaluées** (présent sur seulement 94 214 frames sur 158 857)[3]. Plus critique encore, cette absence n'est pas uniforme : le ballon disparaît précisément lors des actions décisives qui provoquent les changements de possession ou les sorties de balle — duels aériens où le ballon quitte le plan d'homographie du sol, surfaces de réparation densément peuplées générant des occultations multiples, tacles, et passes appuyées à plus de $80 \text{ km/h}$ où le flou de mouvement (*motion blur*) réduit le ballon à une traînée de quelques pixels indistincte des lignes blanches du terrain[3]. Traiter ces 64 643 frames évaluées sans ballon par un simple maintien aveugle de la dernière coordonnée connue dégrade la détection des transitions ; il est indispensable d'inférer la trajectoire latente du ballon à partir de la dynamique collective des 22 joueurs et du flux vidéo[3].

En outre, une règle déterministe issue de l'inspection des bornes temporelles de DATA.md et FAQ.md offre un gain immédiat : alors que la première mi-temps est évaluée dès l'instant exact du coup d'envoi (frame 11 185), **la seconde mi-temps est évaluée dès la frame 110 808 mais le coup d'envoi réel n'a lieu qu'à la frame 113 742**[3]. Ces **2 934 frames initiales (117,36 secondes)** sont intégralement notées et ont pour vérité terrain certaine le label D, tandis que les 40 462 frames hors périodes de jeu (0–11 184, 90 652–110 807, 190 198–199 318) doivent

être forcées à X[3].

## 2.2 Smart Tagging : Intégration Bayésienne des Priors Tactiques et Résolution des Touches

Le fichier BAR-ATH_tactical_smart_tagging.xml contient 638 annotations automatiques parfaitement alignées sur la base temporelle de la vidéo tactique via la relation vérifiée $\text{video_frame} = \text{round}(\text{seconds} \times 25)$ [3]. Bien que généré automatiquement par Metrica Sports sans révision humaine (comportant donc du bruit aux frontières et de possibles erreurs d'inférence), cet actif constitue un **prior bayésien à haute valeur ajoutée** à condition de modéliser correctement la sémantique de ses 14 codes et de ses groupes de tags, tout en prenant garde à la casse exacte et à la coquille orthographique présente dans le fichier XML où la colonne Team prend les valeurs Barcelona, Atletic Club (sans 'h') et N/A[1].

| Catégorie Fonctionnelle | Codes Smart Tagging Associés (Occurrences) | Équipe Taguée (Team) | Implication Probabiliste sur le Label (H, A, D\text{H, A, D}H, A, D) |
|---|---|---|---|
| **Phases Offensives (Polarité Directe)** | PLAYERS IN THE BOX (97), BALL IN FINAL THIRD (93), BALL IN THE BOX (72), PROGRESSION (66), CREATING CHANCES (30), LONG BALL (29), ATTACKING TRANSITION (24), BUILD UP (22)[1] | Barcelona ou Atletic Club [cite: 3] | Forte probabilité que le ballon soit vivant (H ou A) et contrôlé par **l'équipe mentionnée dans le tag Team**[1]. Attention : une phase de BUILD UP ou PROGRESSION peut englober une courte perte de balle ou deux possessions successives[3]. |
| **Phases Défensives (Polarité Inversée)** | DEFENDING IN MIDDLE THIRD (66), DEFENDING IN DEFENSIVE THIRD (30), DEFENSIVE TRANSITION (24), | Barcelona ou Atletic Club [cite: 3] | L'équipe taguée défend, ce qui implique que **l'équipe adverse détient la possession** (Team |

| | | | |
|---|---|---|---|
| | DEFENDING IN ATTACKING THIRD (22)[1] | | = Barcelona $\Longrightarrow$ prior fort pour A ; Team = Atletic Club $\Longrightarrow$ prior fort pour H)[1]. |
| **Coups de Pied Arrêtés Identifiés** | SET PIECES (33 sur 59) : Corner Kick (12), Goal Kick (10), Free Kick (5), Kick Off (After Goal) (4), Kick Off (Start) (2)[3] | Barcelona ou Atletic Club [cite: 3] | Signature structurelle diphasique : la fenêtre temporelle **précédant immédiatement** la reprise est un arrêt de jeu (D), et l'instant de frappe marque le début d'une possession vivante pour Team[1]. |
| **Touches Non Attribuées (Anomalie N/A)** | SET PIECES de type Throw-in (26 occurrences sur 59) + 10 autres événements[3] | **N/A (100 % des touches)** [cite: 3] | Le tag signale la frontière temporelle d'une remise en jeu après un état D (ballon sorti en touche), mais **ne donne pas l'équipe exécutante**[3]. L'équipe doit être inférée par géométrie locale (joueur isolé sur la ligne de touche $y \approx$ ou $y \approx$ ) et par le tag tactique subséquent[3]. |
| **Événements de Buts** | GOALS (4 occurrences)[1] | Barcelona ou Atletic Club [cite: 3] | Fin immédiate de la possession de l'équipe marqueuse ; déclenche une |

| | | | |
|---|---|---|---|
| | | | longue séquence déterministe d'état **D** (célébration et replacement) qui se poursuit strictement jusqu'au Kick Off (After Goal) suivant[1]. |

L'exploitation optimale de ce tableau consiste à ne jamais copier brutalement un intervalle de Smart Tagging comme étiquette finale — ce qui importerait ses erreurs de cadrage temporel — mais à projeter chaque instance sous forme de caractéristiques continues d'appartenance et de proximité aux frontières temporelles[3]. En particulier, la résolution algorithmique des 26 rentrées de touche (Throw-in systématiquement étiquetées Team = N/A) offre un avantage compétitif majeur : l'instant précis de la remise en jeu est localisé par le croisement entre l'intervalle du tag, la présence d'un unique joueur à la périphérie immédiate des lignes de touche ($y \leq 0,02$ ou $y \geq 0,98$) et l'accélération subséquente du ballon vers l'intérieur du terrain[3].

## 2.3 Vidéo Tactique, Homographie et Alignement Multi-Vues du Flux Broadcast

L'homographie tactique ($H_t \in \mathbb{R}^{3\times3}$) est valide sur 100 % des frames[3]. Outre son rôle premier de projection géométrique entre les coordonnées normalisées du terrain $[0,1]^2$ et les pixels $(u,v)$ de la vidéo $1920 \times$ , la colonne reprojection_error constitue elle-même une variable explicative gratuite : sa médiane est de 0,24 pendant le jeu mais s'élève à ~1,5 durant la mi-temps ou lorsque la caméra bouge anormalement[3].

Concernant le **flux Broadcast** (164 488 frames, non synchronisé, comportant des coupures, ralentis et plans serrés), une approche naïve consisterait à l'écarter en raison de l'absence de table d'alignement[3]. Cependant, sur les **65,8 % de frames où l'homographie broadcast est valide** (valid = 1), l'ATD broadcast fournit les positions projetées au sol des joueurs visibles ainsi que la position du ballon sur 50,5 % des frames[3]. Étant donné que la configuration spatiale instantanée de ~20 joueurs en mouvement sur un terrain de $105,3 \times 68,0\ \mathrm{m}$ forme une empreinte géométrique unique à chaque vingt-cinquième de seconde, il est mathématiquement aisé de synchroniser chaque segment continu valide du flux broadcast sur la timeline tactique de référence en minimisant la **distance de Chamfer bidirectionnelle** entre le nuage de points des joueurs tactiques $\mathcal{P}_t^{\mathrm{tact}}$ et celui des joueurs broadcast $\mathcal{P}_\tau^{\mathrm{bcast}}$ sous une contrainte de dérive temporelle monotone ($\tau_{k+1} = \tau_k + 1$) :

$$d_{\text{Chamfer}}\left(\mathcal{P}_t^{\text{tact}}, \mathcal{P}_\tau^{\text{bcast}}\right) = \frac{1}{|\mathcal{P}_t^{\text{tact}}|}\sum_{p\in\mathcal{P}_t^{\text{tact}}}\min_{q\in\mathcal{P}_\tau^{\text{bcast}}}\|p-q\|_2^2 + \frac{1}{|\mathcal{P}_\tau^{\text{bcast}}|}\sum_{q\in\mathcal{P}_\tau^{\text{bcast}}}$$

Une fois cette table de correspondance $\tau \mapsto t$ établie par programmation dynamique sur les segments valid = 1, toutes les frames où la caméra broadcast détecte le ballon alors que l'ATD tactique affiche NaN (notamment lorsque l'angle de vue plus bas de la caméra TV évite une occultation présente sur la vue plongeante tactique) permettent d'injecter directement (ball_x, ball_y) sans aucun coût d'inférence GPU[3]. De plus, l'apparition d'une coupure d'homographie broadcast (valid = 0 pour cause de ralenti TV ou de gros plan sur un joueur) est fortement corrélée aux arrêts de jeu (D), offrant un prédicteur exogène précieux pour détecter les sorties de balle[3].

# 3. Benchmark Approfondi des Modèles par Sous-Tâche Fonctionnelle

Pour atteindre un score spellF1 de premier plan sur un match complet, un modèle monolithique bout-en-bout est voué à l'échec en raison de l'absence d'identités joueurs, du taux de 41 % de ballon manquant et de la taille réduite de la vérité terrain publique (7 500 frames)[3]. Le problème doit être décomposé en trois piliers algorithmiques : l'imputation et la détection du ballon, l'encodage spatial pour la classification frame-par-frame, et la segmentation temporelle séquentielle[9].

## 3.1 Pilier 1 : Imputation et Reconstruction de la Trajectoire du Ballon (41 % de NaN)

Lorsque ball_x et ball_y sont manquants dans l'ATD tactique, cinq familles de modèles complémentaires s'affrontent selon la durée de l'occultation et le budget de calcul disponible[3].

| Modèle / Approche | Architecture & Mécanisme | Forces Spécifiques sur BAR-ATH | Limites & Modes de Défaillance | Gain Attendu & Complexité |
|---|---|---|---|---|
| **Filtre de Kalman État-Étendu + Lisseur RTS (Rauch-Tung-Striebel) / PCHIP** | Modèle d'état cinématique $[x, y, v_x, v_y, a_x$ bidirectionnel (passe avant/arrière) ou interpolation | Temps de calcul négligeable (< 2 s sur 199k frames) ; reconstruit parfaitement les passes | Échoue dès qu'un joueur dévie, contrôle ou renvoie le ballon *pendant* une occultation prolongée ( | **Indispensable (Baseline Niv. 1)** pour combler les micro-trous ( $<$ frames)[18]. |

| | | | | |
|---|---|---|---|---|
| | cubique monotone par morceaux[17]. | rectilignes et les courtes occultations ( $<$ / 25 frames) sans apprentissage[17]. | $>$ ), car l'hypothèse de mouvement balistique continu est violée[17]. | |
| **BallRadar (Set Transformer + Bi-LSTM Hiérarchique)** | Encodeur *Set Transformer* invariant par permutation sur les 46 slots joueurs $(x_i, y_i, v_{x,i}, v_{y,i})$, suivi d'un Bi-LSTM hiérarchique inférant la position latente du ballon[13]. | Exploite le fait que les 22 joueurs agissent comme des capteurs humains qui convergent et orientent leurs courses vers le ballon (« attracteur » dynamique) même quand la caméra le perd[15]. **Entraînable en auto-supervision sur les 113 488 frames visibles du match**[3]. | Précision spatiale de l'ordre de $1,5$ à $3,0$ m RMSE lors des longues phases aériennes ; nécessite de prédire un score d'incertitude gaussienne ( $\sigma_t$)[15]. | **Très Élevé (Cœur du Niv. 2)** : résout les occultations longues ( $>$ ) dans les zones denses[15]. |
| **WASB (Widely Applicable Strong Baseline - HRNet)** | Réseau convolutif haute résolution (HRNet) prenant 3 frames consécutives pour générer des cartes de | État de l'art sur la détection de petits ballons rapides ; conserve la résolution spatiale fine nécessaire pour distinguer un ballon de 4 | Coût GPU élevé s'il est exécuté sur les 199 319 frames complètes ; sensible aux faux positifs statiques (points de penalty, arcs | **Élevé en mode ciblé (Niv. 3)** : à exécuter uniquement sur des *crops* $512 \times 512$ lors des NaN critiques[17]. |

| | | | | |
|---|---|---|---|---|
| | chaleur (*heatmaps* gaussiennes 2D) avec filtrage de cohérence temporelle[22]. | pixels sur le plan large $1920 \times$ [12]. | de cercle, crampons blancs) s'il n'est pas filtré[12]. | |
| **TOTNet (Temporal Occlusion Tracking Network) / TrackNetV3-V4** | Encodeur hybride combinant convolutions spatiales 2D et convolutions temporelles 3D (sur 5 frames) ou cartes d'attention de mouvement, entraîné avec masquage synthétique d'occultation[17]. | Conçu spécifiquement (2025-2026) pour maintenir la localisation du ballon sous occultation partielle ou totale prolongée grâce au contexte spatio-temporel 3D et aux poids de perte dépendants de la visibilité[17]. | Redimensionnement standard ( $288 \times$ ) trop grossier s'il est appliqué à l'image tactique entière ; doit impérativement opérer sur une région d'intérêt (ROI) centrée sur le centroïde d'action prédit par *BallRadar*[12]. | **Élevé en cascade** (ROI guidée par *BallRadar* + projection inverse $H_t^{-1}$ )[3]. |
| **FootAndBall (Komorowski et al.)** | Réseau entièrement convolutif léger à architecture Feature Pyramid Network (FPN, ~199 000 paramètres) détectant conjointement joueurs et ballon[12]. | Extrêmement rapide (37 fps en HD sur GPU standard, 200× plus léger que YOLO), fusionne les caractéristiques basse et haute résolution pour capter le contexte autour du ballon[12]. | Moins robuste que WASB ou TOTNet lorsque le ballon est totalement masqué par un amas de joueurs ou subit un flou cinétique extrême lors des frappes lourdes[12]. | **Modéré** : utile comme détecteur de candidats rapides, mais surpassé par WASB/TOTNet[1][2]. |

L'approche optimale ne consiste pas à ré-exécuter un modèle de vision lourd sur les 199 319

frames de la vidéo tactique, mais à déployer une **imputation hybride en cascade**[3]. Dans un premier temps, le recalage par distance de Chamfer du flux Broadcast permet de récupérer gratuitement les coordonnées du ballon sur les frames où la caméra TV le détecte[3]. Dans un deuxième temps, pour les trous courts ($\leq 15$ frames / $0,6\ \mathrm{s}$) où la vitesse d'entrée et de sortie est cohérente avec une trajectoire sans rebond, un lisseur de **Kalman-RTS / PCHIP** reconstruit la position exacte[17]. Enfin, pour les occultations prolongées ($> 15$ frames, typiques des duels et cafouillages dans la surface), un modèle **BallRadar (Set Transformer + Bi-GRU)** est entraîné en **auto-supervision pure sur les 113 488 frames du match où le ballon est visible**[3]. En masquant artificiellement des segments continus de 10 à 100 frames sur les trajectoires connues du match BAR-ATH (stratégie d'*Occlusion Augmentation*[17]), le réseau apprend la géométrie exacte du pressing du FC Barcelona et de l'Athletic Club sans nécessiter la moindre étiquette de possession[3]. Si une incertitude résiduelle subsiste aux frontières de transition, un détecteur **WASB** ou **TOTNet** est appelé uniquement sur un *crop* haute résolution de $512 \times 512$ pixels centré autour de la position estimée par *BallRadar* (projetée dans l'image via $H_t$), puis reconverti en coordonnées terrain via $H_t^{-1}$[3].

## 3.2 Pilier 2 : Encodage Spatial et Classification Frame-par-Frame Sans Identités Joueurs

Une fois la position du ballon $(x_t^b, y_t^b)$ (et son indicateur de visibilité/incertitude $\sigma_t^b$) disponible sur chaque frame, le second pilier consiste à estimer les probabilités instantanées d'émission $P(y_t \in \{\mathrm{H}, \mathrm{A}, \mathrm{D}\} \mid \mathcal{X}_t)$ à partir de la géométrie des 46 slots de tracking et des priors de Smart Tagging[3].

| Modèle / Famille | Représentation des Entrées | Forces et Adéquation au Problème | Faiblesses & Risques | Recommandation |
|---|---|---|---|---|
| **Modèle Physique de Pitch Control (Fernandez & Bornn 2018 / Spearman 2017)** | Positions $(x_i, y_i)$, vecteurs vitesse $(v_{x,i}, v_{y,i})$ dérivés par filtre de Savitzky-Golay sur les slots localement continus, et | Développé spécifiquement au FC Barcelona[14] ; **totalement invariant par permutation** et insensible aux changements d'IDs (somme | Ne distingue pas nativement l'état D (hors jeu) et peut attribuer le contrôle à l'équipe A lorsqu'une passe de H traverse rapidement | **Caractéristique (Feature) maîtresse obligatoire** à injecter dans les modèles d'apprentissage[14]. |

| | | | | |
|---|---|---|---|---|
| | position du ballon $(x_t^b, y_t^b)$[14]. | des surfaces d'influence gaussiennes anisotropes de chaque joueur) ; fournit une probabilité physique continue de contrôle territorial au point du ballon $PC(p_b, t) \in$ [14]. | une zone dense de A sans être interceptée[4]. | |
| **GBDT (LightGBM / CatBoost / XGBoost) sur Descripteurs Cinématiques Ordonnés** | Vecteur tabulaire invariant par tri : distances et vitesses d'approche des $K =$ joueurs les plus proches de chaque équipe, *Pitch Control*, cinématique du ballon ( $v_b, a_b$), centroïdes/enveloppes convexes, et encodage du Smart Tagging[3]. | **Efficacité échantillonnale imbattable** en régime de faible supervision ; gère nativement les valeurs manquantes (NaN) ; capture les interactions non linéaires entre la vitesse du ballon (passe vs contrôle), la distance du joueur le plus proche et les tags tactiques[13]. | Aveugle à la dynamique séquentielle longue s'il ne reçoit pas de fenêtres glissantes multi-échelles ; ses prédictions brutes scintillent aux frontières sans décodeur temporel aval[5]. | **Backbone de classification frame-par-frame de référence (Tier 1)**[31]. |
| **Set Transformer / DeepSets (Lee** | Ensemble non ordonné de $N_t$ vecteurs | **Mathématiquement conçu pour les** | Risque élevé de sur-apprentiss | **Excellent en hybride (Tier 2)** : |

| | | | | |
|---|---|---|---|---|
| **et al. / FootBots Social Attention)** | joueurs $\{(x_i, y_i, v_{x,i}, v_$ traité par des blocs d'auto-attention multi-têtes avec *Induced Set Attention* et *Pooling by Multihead Attention*[15]. | **ensembles de taille variable sans identifiant** (gère nativement le fait que $N_t$ varie de 18 à 24 joueurs détectés sans *padding* arbitraire) ; l'attention sociale capture les lignes de passe et la structure de pressing[3]. | age (*overfitting*) s'il est entraîné uniquement sur les 17 possessions publiques sans pré-entraînement auto-supervisé ou pseudo-labellisation[5]. | pré-entraîner l'encodeur sur l'imputation du ballon (*BallRadar*), puis geler/fine-tuner[15]. |
| **Réseaux de Neurones Graphiques Spatio-Temporels (ST-GCN / GATv2)** | Graphe $\mathcal{G}_t =$ où les nœuds sont les joueurs valides et le ballon, et les arêtes connectent les entités proches pondérées par distance inverse et vitesse relative[13]. | Modélise finement les duels locaux (sous-graphe autour du ballon) et la topologie tactique globale[13]. | La construction de graphes dynamiques sur 199 319 frames est coûteuse en mémoire/CPU ; redondant avec le *Set Transformer* dont l'attention complète est un graphe complet pondéré[16]. | **Secondaire** : privilégier le *Set Transformer* combiné à LightGBM pour la simplicité et la vitesse[16]. |
| **VLM / Modèles Vidéo (Soccer-CLIP / ActionCLIP /** | Flux d'images RGB de la vidéo tactique ou broadcast découpé en clips vidéo[32]. | Capte des indices visuels absents du tracking : gestuelle de l'arbitre, | Trop lourd pour traiter l'intégralité des 106 minutes en haute résolution ; | **Usage chirurgical uniquement** : classifieur visuel léger sur les 26 touches |

| | | | | |
|---|---|---|---|---|
| **SpotFormer)** | | posture du gardien tenant le ballon en main, joueur effectuant une rentrée de touche, ballon franchissant la ligne[3]. | sur-ajuste le décor visuel d'un seul match[12]. | (Team = N/A) et arrêts de jeu ambigus[3]. |

### Ingénierie des Caractéristiques Spatio-Temporelles Invariantes par Permutation

Pour que le classifieur frame-par-frame (qu'il s'agisse de LightGBM ou d'une tête neuronale) distingue avec précision un **contrôle effectif** d'un simple **rebond, contre ou duel aérien** conformément aux règles de CHALLENGE.md, et sépare le jeu actif (H/A) des arrêts de jeu (D), l'extraction de caractéristiques à chaque frame $t$ doit articuler cinq familles de descripteurs invariants par permutation[4].

En premier lieu, le pipeline doit construire une **cinématique d'interaction joueur-ballon ordonnée**, directement inspirée des travaux récents de synchronisation d'événements à 25 fps (MLSA 2025)[13]. Pour chaque équipe $c \in \{\mathrm{H}, \mathrm{A}\}$, les joueurs valides à l'instant $t$ sont triés par distance croissante au ballon $d^c_{(1)}(t) \leq d^c_{(2)}(t) \leq d^c_{(3)}(t)$ [13]. Le modèle extrait non seulement ces distances en mètres, mais également le rapport de proximité $r_1(t) = \frac{d^H_{(1)}(t)+\epsilon}{}$, la vitesse radiale d'approche du joueur le plus proche vers le ballon, ainsi que la durée continue pendant laquelle un joueur de l'équipe $c$ se maintient dans un rayon de contrôle strict ($< 1,5\ \mathrm{m}$)[4]. La combinaison de la distance joueur-ballon minimale (*Closest Player-Ball Distance - CPBD*), de l'accélération scalaire du ballon (*Ball Acceleration - BA*) et des distances maximales avant et après impact (*Pre-KD* et *Post-KD*) permet d'isoler l'instant exact d'une passe ou d'une réception contrôlée par rapport à une simple déviation[4].

En deuxième lieu, cette proximité ponctuelle doit être enrichie par la **surface de contrôle paramétrique (Pitch Control de Fernandez & Bornn)**, développée spécifiquement en collaboration avec le FC Barcelona[14]. L'influence spatiale $I_i(p,t)$ de chaque joueur $i$ au point du ballon $p_b = (x^b_t, y^b_t)$ est modélisée par une distribution normale bivariée dont la moyenne $\mu_i(t) = p_i(t) + 0.5 \cdot v_i(t)$ est projetée dans la direction du vecteur vitesse instantané et dont la matrice de covariance $\Sigma_i(t)$ s'allonge selon la vitesse $s_i(t)$ et s'élargit avec la distance au ballon[14]. L'agrégation des influences individuelles par une fonction logistique produit alors un estimateur continu, dérivable et robuste au bruit de tracking qui résume la domination spatiale locale autour du ballon[14] :

$$PC_H(p_b, t) = \sigma\left(\sum_{i \in \text{Home}} I_i(p_b, t) - \sum_{j \in \text{Away}} I_j(p_b, t)\right)$$

En troisième lieu, l'identification fiable de l'état D (*Dead Ball*) lorsque le ballon est absent (NaN) repose sur la **thermodynamique collective des 22 joueurs**[3]. Dès que l'arbitre siffle ou que le ballon franchit les limites du terrain, la vitesse moyenne $\bar{s}(t) = \frac{1}{N_t}\sum_{i=1}^{N_t} s_i(t)$ et le 90e centile des vitesses individuelles chutent brutalement (transition course $\rightarrow$ marche), la dispersion spatiale des vitesses s'effondre, et le vecteur de déplacement global des centroïdes d'équipes s'annule ou converge lentement vers une zone de remise en jeu[3]. Associées à la distance géométrique du ballon aux lignes de touche ($y \notin [0, 1]$) et de but ($x \notin [0, 1]$) dans les frames précédant sa disparition, ces variables collectives discriminent l'état D avec une très haute fidélité[3].
En quatrième lieu, le modèle intègre un **encodage temporel dense du Smart Tagging** et des indicateurs de caméra[1]. Pour chaque frame $t$, le vecteur de caractéristiques inclut non seulement les indicateurs binaires et la polarité d'équipe (+1 pour H, -1 pour A, 0 pour N/A) des 14 codes actifs à l'instant $t$, mais surtout les distances temporelles signées aux frontières d'événements ($\Delta t_{\text{start}} = t - t_{\text{début_tag}}$ et $\Delta t_{\text{end}} = t_{\text{fin_tag}} - t$), telles que le temps restant avant un SET PIECES ou le temps écoulé depuis un GOALS, complétées par l'erreur de reprojection d'homographie tactique et l'état de validité de l'homographie broadcast[1].
Enfin, puisque la tâche est résolue en mode hors-ligne (*offline*, l'intégralité de la séquence du match étant accessible lors de l'inférence[4]), toutes ces variables primaires font l'objet d'**agrégations multi-échelles causales et anti-causales**[5]. Le calcul des moyennes, écarts-types, minimums, maximums et différences finies (contraste entre le futur immédiat et le passé immédiat : $\bar{x}_{[t,t+W]} - \bar{x}_{[t-W,t]}$) sur des fenêtres symétriques et asymétriques $W \in \{12, 25, 50, 125, 250\}$ frames ($0,5$ s à $10$ s) agit comme un détecteur de point de rupture (*change-point detector*) particulièrement discriminant pour localiser à la frame près les transitions de possession[4].

## 3.3 Pilier 3 : Segmentation Temporelle d'Actions et Décodage Séquentiel (Optimisation spellF1)

C'est à ce troisième niveau que se joue la performance finale sur spellF1[5]. Transformer une séquence de probabilités frame-par-frame bruitées $\mathbf{P} \in [0, 1]^{199\,319 \times 3}$ en une partition d'intervalles continus maximisant le score $\text{F1@IoU}$ sur $\{0.3, \ldots, 0.7\}$ relève directement de la littérature de **Temporal Action Segmentation (TAS)**[5].

| Architecture de Segmentation | Principe Mathématique & Réceptivité | Avantages décisifs pour spellF1 | Inconvénients & Contraintes | Verdict Benchmark |
|---|---|---|---|---|
| **HSMM / HMM Inhomogène + Décodage de Viterbi** | Modèle de Markov Caché (ou Semi-Markovien avec loi de durée explicite $P(d \mid$ ) où les probabilités de transition $A_t(i \rightarrow$ dépendent du contexte cinématique instantané (visibilité du ballon, vitesse, Smart Tagging)[10]. | **Interprétabilité et contrôle absolus** : permet d'encoder directement les règles métier de CHALLENGE.md (ex. interdire une transition $\mathrm{H} \leftrightarrow$ lorsque le ballon est NaN ou que sa vitesse dépasse $15\ \mathrm{m/s}$ en plein vol ; imposer une durée minimale de contrôle)[4]. Aucun risque de sur-apprentissage[5]. | Les paramètres d'échelle (pénalité de transition $\lambda_{\text{trans}}$ et biais d'état) doivent être calibrés avec soin (par validation sur données externes + contrôle de cohérence sur les 5 min publiques)[5]. | **Indispensable comme couche de décodage finale (Post-Processor / Décodeur Global)**[34]. |
| **MS-TCN++ (Multi-Stage Temporal Convolutional Network)** | Empilement de plusieurs étages (*stages*) de raffinement composés de convolutions 1D dilatées | **Architecture reine pour le Segmental F1 (spellF1)** dans la littérature CVPR/TPAMI[10]. Chaque étage de raffinement | Nécessite des séquences d'entraînement continues : doit être entraîné sur des matchs externes (Metrica Open | **Meilleur modèle neuronal de segmentation temporelle (Tier 1 TAS)**[10]. |

| | | | | |
|---|---|---|---|---|
| | résiduelles ( $d =$ , sans *pooling* temporel) opérant à pleine résolution (25 fps), entraînées avec une perte de classification couplée à une perte de lissage **T-MSE**[6]. | prend uniquement les probabilités de sortie de l'étage précédent et apprend à supprimer les sur-segmentations (*flickering*) tout en affinant la localisation des frontières à la frame près[6]. | Data) et/ou par supervision partielle (*Timestamp/Anchor Supervision*) sur le match cible[6]. | |
| **ASFormer / ActionFormer (Transformers Temporels)** | Remplace ou hybride les convolutions dilatées par des mécanismes d'auto-attention et d'attention croisée hiérarchique restreints à des fenêtres locales croissantes[36]. | Excellente capacité à modéliser des dépendances à très longue portée et à localiser les moments d'action sans ancres (*anchor-free*)[39]. | Plus lourd en paramètres et nettement plus sujet au sur-apprentissage que MS-TCN++ lorsque le volume de données annotées est limité (constat confirmé dans les benchmarks SoccerNet / E2E-Spot[41]). | **Tier 2** : utile en *ensembling* avec MS-TCN++, mais moins robuste seul en régime frugal[41]. |
| **Bi-GRU / Bi-LSTM + Couche CRF Linéaire (Conditional Random Field)** | Réseau récurrent bidirectionnel encodant le contexte temporel suivi d'un champ | La couche CRF apprend explicitement les coûts de transition entre H, A et D tout en bénéficiant | Les RNN lissent parfois excessivement les frontières rapides et souffrent d'oubli sur de | **Solide alternative légère** au MS-TCN++[35]. |

| | | | | |
|---|---|---|---|---|
| | aléatoire conditionnel maximisant la probabilité globale de la séquence par programmation dynamique[15]. | des représentations récurrentes bidirectionnelles[35]. | très longues séquences (> 1 000 frames) face aux convolutions dilatées de MS-TCN++[7]. | |
| **Vote Majoritaire / Filtre Médian Glissant (baseline_smooth50)** | Fenêtre glissante uniforme de taille fixe $W$ (ex. $W =$ frames) prenant le mode statistique[2]. | Extrêmement simple (numpy pur), établit le plancher de 0,2433 spellF1[2]. | **Aveugle au contexte** : décale les frontières lorsque les durées sont asymétriques et efface systématiquement toute possession réelle de durée inférieure à $W/2$[2]. | **Obsolète au-delà de la baseline** : à remplacer par MS-TCN++ et Viterbi HSMM[5]. |

**Formulation Mathématique du Couplage MS-TCN++ et Décodage HSMM Inhomogène**

Dans **MS-TCN++** (Li et al., TPAMI 2020 ; Abu Farha & Gall, CVPR 2019), la perte d'entraînement de chaque étage combine l'entropie croisée par frame $\mathcal{L}_{\text{cls}}$ avec une perte de régularisation temporelle **Truncated Mean Squared Error (T-MSE)** sur les log-probabilités adjacentes, conçue spécifiquement pour maximiser le score F1 segmentaire (spellF1)[6] :

$$\mathcal{L}_{\text{total}} = \sum_{s=1}^{S} \left( \mathcal{L}_{\text{cls}}^{(s)} + \lambda \cdot \mathcal{L}_{\text{T-MSE}}^{(s)} \right), \quad \text{où} \quad \mathcal{L}_{\text{T-MSE}} = \frac{1}{T \cdot C} \sum_{t=1}^{T} \sum_{c \in \{\text{H,A,D}\}}$$

L'écrêtage au seuil $\tau$ (typiquement $\tau = 4$) est fondamental : il force les probabilités à rester constantes à l'intérieur d'une possession (éliminant le *flickering*), tout en autorisant des sauts francs et nets ($\Delta > \tau$) aux véritables frontières de changement de possession sans les pénaliser ni les étaler dans le temps[6].

Pour garantir en sortie le respect strict de la logique métier du football décrite dans

CHALLENGE.md, les probabilités lissées $\hat{\mathbf{p}}_t$ issues de l'ensemble (LightGBM + MS-TCN++) alimentent un **décodeur de Viterbi à matrice de transition inhomogène** $\mathbf{A}_t$ [4]. Au lieu d'utiliser un coût de transition fixe, la probabilité de basculer de l'équipe H vers l'équipe A à la frame $t$, notée $A_t(\mathrm{H} \to \mathrm{A})$, est modulée par une porte cinématique $g_t(\mathrm{A}) \in [0,1]$ :

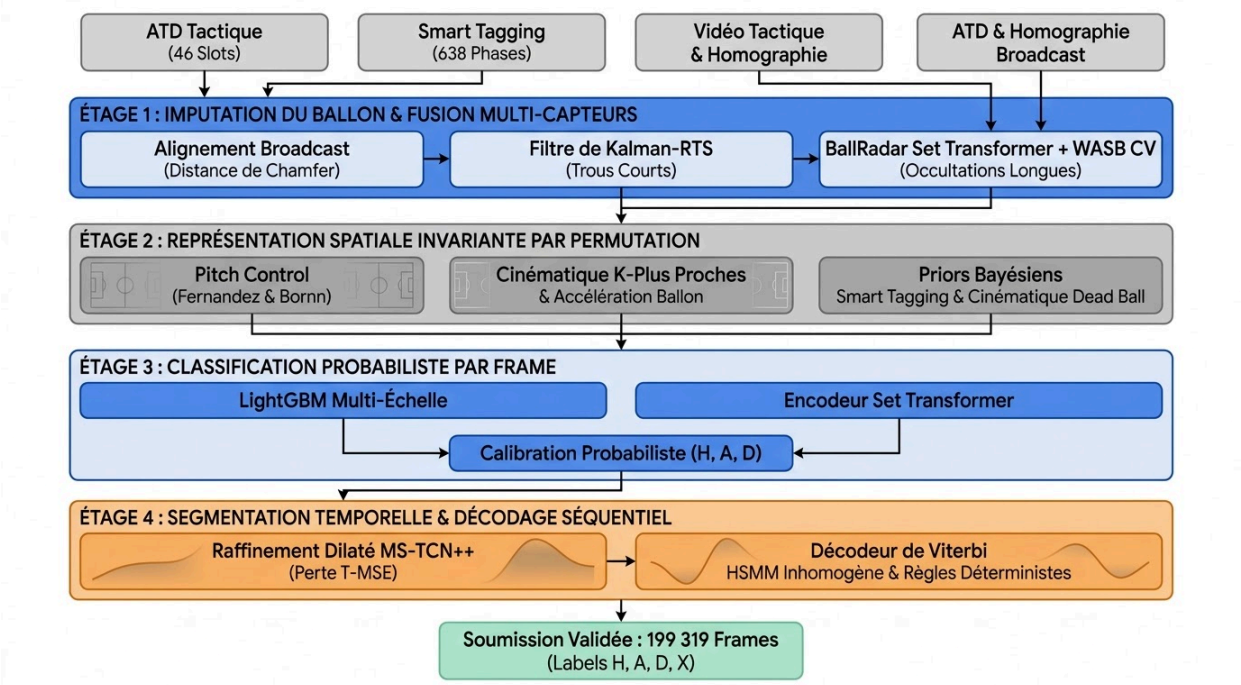
$$A_t(\mathrm{H} \to \mathrm{A}) = \alpha_{\text{base}} \cdot g_t(\mathrm{A}), \quad \text{avec} \quad g_t(\mathrm{A}) = \mathbb{I}(\text{ballon visible ou impu}$$

Lorsque le ballon est en l'air, loin de tout joueur de l'équipe A ($d^A_{(1)}(t) > 2,5\ \mathrm{m}$) ou simplement dévié à grande vitesse sans contrôle ($v^A_{\text{rel}}(t)$ élevée), la porte $g_t(\mathrm{A})$ tend vers 0[4]. L'algorithme de Viterbi est alors mathématiquement contraint de **maintenir l'état H à travers toute la phase disputée ou l'occultation**, reproduisant exactement la règle officielle selon laquelle, durant les phases où le ballon est disputé ou libre, la possession demeure attribuée à la dernière équipe qui la détenait[4].

# 4. Architecture Cible Recommandée et Stratégie d'Entraînement à Faible Supervision

## 4.1 Architecture Hybride en Quatre Étages (Pipeline de Production)

L'intégration des meilleurs modèles identifiés dans le benchmark conduit à une architecture modulaire en quatre étages, conçue pour maximiser spellF1 tout en garantissant une reproductibilité déterministe conforme aux exigences de RULES.md et SUBMISSION.md[11].




Dans cette architecture séquentielle, chaque étage isole une difficulté mathématique spécifique afin d'éviter la propagation d'erreurs non contrôlées[3]. L'Étage 1 transforme les séries temporelles incomplètes en une trajectoire continue du ballon accompagnée d'un vecteur de variance d'estimation, en fusionnant l'alignement géométrique du flux Broadcast, le lissage cinématique de Kalman-RTS sur les brèves interruptions et l'inférence multi-agents *BallRadar* assistée par détection visuelle WASB sur les occultations complexes[3]. L'Étage 2 convertit ensuite les coordonnées brutes des 46 slots anonymes en un tenseur de descripteurs physiques et tactiques strictement invariant par permutation des identifiants[3]. L'Étage 3 produit des probabilités calibrées $P(y_t \in \{\mathrm{H}, \mathrm{A}, \mathrm{D}\})$ en combinant la robustesse tabulaire de LightGBM et la capacité de représentation relationnelle d'un *Set Transformer*[16]. Enfin, l'Étage 4 résout le problème de segmentation temporelle via MS-TCN++ et applique le décodage global de Viterbi sous contraintes physiques pour générer le fichier de 199 319 lignes parfaitement conforme au contrat de validation[10].

## 4.2 Protocole d'Apprentissage : Auto-Supervision, Pseudo-Labels d'Ancrage et Données Externes

La question méthodologique centrale consiste à entraîner les étages 3 (LightGBM + Set Transformer) et 4 (MS-TCN++) alors que l'échantillon public de vérité terrain ne couvre que 7 500 frames (17 possessions) sur les 158 857 frames évaluées[3]. Le règlement (RULES.md et FAQ.md) interdit formellement toute annotation manuelle de la soumission finale, mais **autorise explicitement l'utilisation de jeux de données ouverts externes, de modèles pré-entraînés, d'annotations manuelles limitées pour l'entraînement ou la validation, ainsi que de toute méthode algorithmique auto-supervisée ou semi-supervisée reproductible à partir du dépôt de code**[4]. Trois leviers d'entraînement complémentaires permettent dès lors

de surmonter la rareté des étiquettes publiques[3].

Le premier levier repose sur la **génération algorithmique de pseudo-labels d'ancrage à très haute confiance (*High-Confidence Anchors*) sur l'intégralité des 158 857 frames évaluées**[3]. Sur l'ensemble du match BAR-ATH, une proportion majeure des frames évaluées présente une configuration physique et tactique dépourvue d'ambiguïté[3]. Un moteur de règles physiques déterministes (visant une précision supérieure à 98 % au prix d'un rappel partiel) permet d'étiqueter automatiquement ces îlots de certitude à travers tout le match. Plus précisément, une ancre de possession vivante (H ou A) est générée lorsque le ballon est visible dans l'ATD tactique, qu'il demeure à moins de $1,2\ \mathrm{m}$ d'un joueur de l'équipe $c \in \{\mathrm{H}, \mathrm{A}\}$ pendant au moins 20 frames consécutives ($0,8\ \mathrm{s}$), qu'aucun joueur adverse ne se trouve dans un rayon de $4,0\ \mathrm{m}$, que le *Pitch Control* $PC_c(p_b, t)$ excède 0,85, et que cette attribution concorde avec la polarité du tag actif dans le Smart Tagging (par exemple une phase de BUILD UP ou PROGRESSION pour l'équipe $c$, ou une phase de DEFENDING pour son adversaire)[1]. De manière analogue, des ancres certaines d'état D (*Dead Ball*) sont placées sur les 2 934 frames pré-coup d'envoi de la seconde période (110 808–113 741), sur les intervalles compris entre la fin d'un événement GOALS et le début du Kick Off (After Goal) suivant, ainsi que sur les fenêtres de 50 à 150 frames précédant immédiatement le déclenchement cinématique (pic d'accélération du ballon) d'un Corner Kick, Goal Kick, Free Kick ou Throw-in lorsque la vitesse moyenne des 22 joueurs est inférieure à $1,8\ \mathrm{m/s}$ ou que le ballon se situe hors des limites $[0,1]^2$ [1].

Le deuxième levier consiste à exploiter ces ancres via un **apprentissage par supervision d'ancres et perte de confiance monotone (*Timestamp/Anchor Supervision*, Li, Abu Farha & Gall, CVPR 2021)**[6]. Comme le démontrent les travaux de référence en segmentation d'actions sous supervision partielle, il n'est nullement nécessaire de connaître les frontières exactes de chaque segment d'entraînement pour entraîner efficacement **MS-TCN++**[6]. En combinant les 7 500 frames de la vérité terrain publique (supervision complète à 100 %) avec les pseudo-labels d'ancrage disséminés sur les 151 357 autres frames évaluées du match, le réseau est optimisé à l'aide d'une perte d'entropie croisée masquée (calculée uniquement sur les ancres) couplée à la perte de confiance monotone $\mathcal{L}_{\mathrm{conf}}$ et à la perte de lissage $\mathcal{L}_{\mathrm{T\text{-}MSE}}$ sur l'ensemble des frames[6]. Cette formulation force mathématiquement le réseau à propager les états des cœurs de possession certains jusqu'aux points d'inflexion cinématiques exacts des zones de transition[6].

Le troisième levier mobilise le **pré-entraînement sur données de tracking ouvertes (*Domain Pre-Training*)** afin d'immuniser le pipeline contre le sur-apprentissage[5]. Pour éviter que l'encodeur spatial et les poids temporels ne sur-ajustent les seules 17 possessions publiques, les modèles peuvent être pré-entraînés sur les jeux de données publics de tracking de football à 25 fps — notamment les trois matchs complets *Metrica Sports Sample Data* accessibles nativement via la bibliothèque kloppy, ainsi que les jeux de données ouverts *DFL / Sportec* de

Bundesliga — dont les coordonnées normalisées $[0, 1]$ et la fréquence d'échantillonnage de 25 Hz sont identiques à celles du challenge[3]. En appliquant un bruit de dégradation synthétique (masquage de 41 % des positions du ballon selon un processus markovien et fragmentation aléatoire des trajectoires joueurs en 46 slots) sur ces matchs externes, cette procédure génère un banc de validation hors-échantillon de plusieurs centaines de possessions permettant de calibrer les hyperparamètres de MS-TCN++ et de Viterbi sans jamais sur-ajuster la fenêtre publique de 5 minutes[3].

## 4.3 Feuille de Route d'Implémentation et Règles de Post-Traitement Déterministes

Pour structurer le développement d'ici l'échéance du 17 novembre 2026 et maximiser la progression incrémentale sur spellF1 et macroF1, l'implémentation s'organise autour d'une feuille de route séquentielle en cinq jalons vérifiables[1].

| Jalon d'Ingénierie | Composants Algorithmiques Déployés | Problème Spécifique Résolu | Gain Stratégique sur les Métriques |
|---|---|---|---|
| **Jalon 0 : Hygiène Temporelle & Contraintes Dures** | Masquage exact des 40 462 frames hors-jeu en X ; forçage déterministe des frames 110 808–113 741 (2 934 frames) en D ; validation systématique via validate_submission .py[3]. | Élimine les erreurs d'alignement (off-by-one) et sécurise gratuitement 117,4 secondes d'état D au début de la seconde période[9]. | Gain immédiat et sans risque sur macroF1 et suppression des fausses possessions pré-coup d'envoi sur spellF1[5]. |
| **Jalon 1 : Reconstruction Cinématique du Ballon & Détection D** | Interpolation Kalman-RTS / PCHIP sur les trous courts ; recalage Chamfer du Broadcast ATD ; modèle *BallRadar* (Set Transformer + Bi-GRU) auto-supervisé sur les 113 488 frames | Réduit le taux d'aveuglement du ballon de 40,7 % à < 5% d'incertitude non résolue ; distingue les ballons hors limites (D) des ballons occultés en jeu[3]. | Bond majeur sur le rappel des possessions et la détection des arrêts de jeu (D)[5]. |

| | | | |
|---|---|---|---|
| | visibles[3]. | | |
| **Jalon 2 : Ingénierie Spatiale & Classifieur LightGBM** | Calcul du *Pitch Control* (Fernandez-Bornn), distances/vitesses des $K$-plus proches joueurs, accélération du ballon, polarité Smart Tagging + résolution géométrique des 26 touches (Team = N/A)[3]. | Remplace la règle naïve du « joueur le plus proche » par une estimation probabiliste calibrée intégrant la vitesse, l'orientation et le contexte tactique[5]. | Hausse substantielle du macroF1 et réduction drastique du bruit d'émission[5]. |
| **Jalon 3 : Décodage HSMM / Viterbi Inhomogène** | Remplacement du vote majoritaire glissant (smooth50) par un décodeur de Viterbi dont la matrice de transition est verrouillée pendant les phases disputées/aériennes et ouverte aux impacts contrôlés[4]. | Supprime le scintillement (*flickering*) sans effacer les possessions courtes légitimes (1,5 à 3 s) et aligne les frontières à $\pm 3$ frames de l'impact réel[5]. | **Gain décisif sur spellF1** par alignement topologique des segments[5]. |
| **Jalon 4 : Raffinement MS-TCN++ & Post-Traitement de Durée** | Entraînement de MS-TCN++ (perte T-MSE) sur données externes + ancres du match ; filtrage post-hoc des segments résiduels de confiance $\max_c \hat{p}_{t,c} <$ et de durée $\ell <$ ; remplacement de tout X interne par | Affine le recouvrement temporel aux seuils stricts ( $\mathrm{IoU} >$ et $0,7$) et maximise le tie-breaker macroF1 sans pénaliser spellF1[5]. | Optimisation finale pour le classement principal spellF1 et avantage décisif au tie-break macroF1[1]. |

| | | | |
|---|---|---|---|
| | maintien d'état explicite[5]. | | |

En dernier lieu, une règle de filtrage post-hoc inspirée des méthodes récentes de segmentation temporelle d'actions (CFA / Online-Offline TAS[35]) doit être appliquée immédiatement après le décodage séquentiel : tout segment de possession prédit (H ou A) dont la durée est inférieure à un seuil physique minimal $\ell_{\min} \approx 18$ frames ($0,72$ s) et dont la probabilité maximale moyenne $\bar{q}_s = \frac{1}{|s|}\sum_{t \in s} \max_c \hat{p}_{t,c}$ reste sous un seuil de haute certitude $\theta_{\text{conf}} \approx 0,85$ correspond presque systématiquement à une déviation, un contre ou un duel aérien non contrôlé[4]. Ce micro-segment doit être absorbé par fusion avec la possession précédente lorsqu'il s'inscrit dans une phase disputée continue, éliminant ainsi les faux positifs résiduels qui dégradent simultanément la précision et le rappel bijectif de spellF1[4].

# 5. Conclusions et Recommandations Stratégiques

L'analyse exhaustive du challenge *More than a Hack 2027* démontre que la performance sur la tâche de possession frame-par-frame repose sur l'alignement strict entre la physique des données de tracking et la mécanique de la métrique **spellF1**[4]. La priorité architecturale absolue doit être accordée à la continuité topologique des segments plutôt qu'à la précision ponctuelle par frame[5]. La métrique spellF1 étant un score F1 segmentaire moyenné sur cinq seuils d'$\mathrm{IoU}$ allant de 0,3 à 0,7, l'apparition d'une seule coupure parasite au milieu d'une possession longue coûte infiniment plus cher qu'une imprécision de 2 ou 3 frames sur l'instant exact d'une passe[5]. L'association d'un réseau de segmentation temporelle **MS-TCN++** (entraîné avec la perte de lissage tronquée **T-MSE**) et d'un **décodeur de Viterbi à transitions inhomogènes** constitue dès lors la réponse mathématique optimale pour éradiquer la sur-segmentation tout en préservant la netteté des frontières de transition[6].

Parallèlement, la résolution conjointe du problème des 41 % de ballons manquants et des 46 slots anonymes exige d'exploiter les symétries géométriques et l'auto-supervision[3]. Plutôt que de subir l'absence du ballon sur 64 643 frames évaluées, le pipeline doit tirer parti des **113 488 frames où le ballon est visible** dans l'ATD tactique pour entraîner en auto-supervision un modèle **BallRadar (Set Transformer + Bi-GRU)** capable d'inférer la position latente du ballon à partir des mouvements collectifs des 22 joueurs, complété par l'alignement par distance de Chamfer du flux Broadcast et le filtrage de Kalman-RTS[3]. L'utilisation conjointe du modèle paramétrique de **Pitch Control de Fernandez & Bornn** et de descripteurs cinématiques triés par distance garantit quant à elle une invariance totale face aux permutations d'identités des 46 slots de tracking[3].

Enfin, la compétitivité finale du système repose sur l'exploitation rigoureuse des ancres déterministes du match et de la dissymétrie du label X[3]. En codant en dur les contraintes exactes de l'enregistrement (40 462 frames non évaluées fixées à X, 2 934 frames pré-coup d'envoi de la seconde période fixées à D, séquences post-buts forcées à D, et désambiguïsation géométrique des 26 touches Team = N/A), en entraînant un ensemble

**LightGBM + MS-TCN++** par supervision d'ancres à haute confiance, et en remplaçant toute abstention X sur les frames évaluées par un maintien explicite de l'état précédent, l'architecture s'assure simultanément un score **spellF1** maximal et un avantage décisif sur le critère de départage **macroF1**[3].

### Sources des citations


1. OVERVIEW.md
2. README.md
3. DATA.md
4. CHALLENGE.md
5. EVALUATION.md
6. Temporal Action Segmentation from Timestamp Supervision, https://pages.iai.uni-bonn.de/gall_juergen/download/jgall_timestamp_cvpr21.pdf
7. Spectral Scalpel: Amplifying Adjacent Action Discrepancy via ... - arXiv, https://arxiv.org/html/2603.24134v1
8. Learning Multi-Task Robot Trajectory Segmentation from Visual and, https://openaccess.thecvf.com/content/CVPR2026F/papers/Chen_Learning_Multi-Task_Robot_Trajectory_Segmentation_from_Visual_and_Kinematic_Streams_CVPRF_2026_paper.pdf
9. FAQ.md
10. arXiv:2007.06866v1 [cs.CV] 14 Jul 2020, https://arxiv.org/pdf/2007.06866
11. SUBMISSION.md
12. The Tiny Object Problem: Why Detecting a Football Is Harder Than, https://beach.io/blog/the-tiny-object-problem-detecting-a-football/
13. Event-Tracking Data Synchronization in Soccer Without Annotated, https://dtai.cs.kuleuven.be/events/MLSA25/papers/MLSA25_paper_181.pdf
14. (PDF) Wide Open Spaces: A statistical technique for measuring, https://www.researchgate.net/publication/324942294_Wide_Open_Spaces_A_statistical_technique_for_measuring_space_creation_in_professional_soccer
15. Soccer Analytics 2023 Review - Jan Van Haaren, https://janvanhaaren.be/posts/soccer-analytics-review-2023/
16. A Transformer-based Architecture for Motion Prediction in Soccer, https://arxiv.org/html/2406.19852v1
17. TOTNet: Occlusion-Aware Temporal Tracking for Robust Ball ... - arXiv, https://arxiv.org/pdf/2508.09650
18. The University of Osaka Institutional Knowledge Archive : OUKA, https://ir.library.osaka-u.ac.jp/repo/ouka/all/105500/35617_Dissertation.pdf
19. TOTNet: Occlusion-Aware Temporal Tracking for Robust Ball ... - arXiv, https://arxiv.org/html/2508.09650v1
20. TranSPORTmer: A Holistic Approach to Trajectory Understanding in, https://www.alphaxiv.org/abs/2410.17785
21. Related papers: Ball Trajectory Inference from Multi-Agent Sports, https://fugumt.com/fugumt/paper_check/2306.08206v1_enmode
22. Widely Applicable Strong Baseline for Sports Ball Detection ... - arXiv,

https://arxiv.org/html/2311.05237v2
23. BallTrack: Football ball tracking for real-time CCTV systems, https://www.semanticscholar.org/paper/BallTrack%3A-Football-ball-tracking-for-real-time-Komorowski-Kurzejamski/7e282b4b7607ae5db0e2077c8298b275dd770f2a
24. (PDF) Trajectory-Based Ball Detection and Tracking in Broadcast, https://www.researchgate.net/publication/3424486_Trajectory-Based_Ball_Detection_and_Tracking_in_Broadcast_Soccer_Video
25. Computer Vision and Image Understanding TOTNet, https://rbouadjenek.github.io/assets/pdf/YCVIU_104657.pdf
26. AI Ball Tracking for Sport Analysis | Mercity Research, https://www.mercity.ai/blog-post/ball-tracking-for-sport-analysis/
27. Sports Ball Detection And Tracking - CatalyzeX, https://www.catalyzex.com/s/Sports%20Ball%20Detection%20And%20Tracking
28. A statistical technique for measuring space creation in professional, https://www.lukebornn.com/papers/fernandez_ssac_2018.pdf
29. Modeling the physiological bounds of playable space in football, https://www.biorxiv.org/content/10.64898/2026.07.04.736520v1.full.pdf
30. The science of space creation - Barça Innovation Hub, https://barcainnovationhub.fcbarcelona.com/blog/the-science-of-space-creation/
31. (PDF) Data-driven prediction of soccer outcomes using enhanced, https://www.researchgate.net/publication/386082961_Data-driven_prediction_of_soccer_outcomes_using_enhanced_machine_and_deep_learning_techniques
32. Soccer-CLIP: Vision Language Model for Soccer Action Spotting, https://www.semanticscholar.org/paper/Soccer-CLIP%3A-Vision-Language-Model-for-Soccer-Shin-Park/b4cdb6a42b4eb4565e0fcc5cd024cbc8b002df04
33. Deep learning for action spotting in association football videos, https://repository.kaust.edu.sa/server/api/core/bitstreams/1e3dad33-bdef-4b1f-922d-fa105e75b7d0/content
34. Football tracking data: a copula-based hidden Markov model for, https://www.researchgate.net/publication/360163826_Football_tracking_data_a_copula-based_hidden_Markov_model_for_classification_of_tactics_in_football
35. An Online Baseline for Temporal Action Segmentation - arXiv, https://arxiv.org/pdf/2411.01122
36. Temporal Action Segmentation: An Analysis of Modern Techniques, https://www.researchgate.net/publication/374971079_Temporal_Action_Segmentation_An_Analysis_of_Modern_Techniques
37. Temporal Action Segmentation: A Comprehensive Overview, https://www.emergentmind.com/topics/temporal-action-segmentation
38. RULES.md
39. ASTRA: An Action Spotting TRAnsformer for Soccer Videos - arXiv, https://arxiv.org/html/2404.01891v1
40. Chapter 0 Deep learning for action spotting in association football, https://arxiv.org/html/2410.01304v1

41. Spotting Temporally Precise, Fine-Grained Events in Video, https://jhong93.github.io/pdf/spot-eccv22.pdf
42. more-than-a-hack-2027/requirements-starter.txt at main - GitHub, https://github.com/metrica-sports/more-than-a-hack-2027/blob/main/requirements-starter.txt